Propuesta de Proyecto de Investigación

Maria Sepulveda[*,1]
20202005013
mysepulvedab@udistrital.edu.co

Martin Gil[†,2]
20221005040
mfgilq@udistrital.edu.co

September 23, 2026

Resumen

Este proyecto de investigación propone un estudio comparativo de las diferentes arquitecturas de Redes Neuronales (Perceptrón Multicapa, Funciones de Base Radial y Redes Convolucionales) para abordar un problema complejo de clasificación multiclase: la decodificación de estímulos visuales (dígitos MNIST del 0 al 9) a partir de señales electroencefalográficas (EEG) en bruto. Utilizando la base de datos pública MindBigData 2022 (capturada con el dispositivo Muse2), el proyecto enfrenta los desafíos inherentes a la naturaleza estocástica, ruidosa y linealmente no separable de los datos cerebrales. Se evaluarán múltiples niveles de dimensionalidad y ruido (versiones completa, Cut2 y Cut3). Para los modelos MLP y RBF se implementarán técnicas de preprocesamiento espectral (Transformada Rápida de Fourier - FFT) para extraer características estables, mientras que las CNN evaluarán la extracción automática sobre espectrogramas o series temporales. Los resultados de este estudio aportarán al estado del arte en Interfaces Cerebro-Computadora (BCI), determinando qué paradigma neuronal ofrece el mejor balance entre precisión de decodificación, manejo de ruido y eficiencia computacional.

Palabras clave: Interfaz Cerebro-Computadora (BCI), EEG, Red Neuronal Multicapa (MLP), Función de Base Radial (RBF), Redes Convolucionales (CNN), Transformada de Fourier, MindBigData.

Decodificación de Estímulos Visuales a partir de Señales EEG

La comprensión y decodificación de la actividad electrofisiológica del cerebro humano representa uno de los hitos científicos y computacionales más desafiantes del presente siglo. En la intersección entre la neurociencia cognitiva y la inteligencia computacional, la inferencia de representaciones perceptuales a partir de bioseñales no invasivas promete transformar los paradigmas de interacción humano-máquina. El presente trabajo aborda la clasificación multiclase de percepciones visuales evocadas, explorando el límite empírico entre la portabilidad de sensores electroencefalográficos (EEG) de grado comercial y la capacidad de aproximación de diversas arquitecturas de redes neuronales.

Ficha de Datos y Plataforma Experimental:

- **Corpus:** *MindBigData 2022 (Visual MNIST Brain Dataset)* [1].
- **Hardware sensor:** Interaxon *Muse 2* (4 electrodos activos: TP9, AF7, AF8, TP10; $f_s = 256$ Hz).
- **Variantes evaluadas:** *Full* (72,000 ensayos), *Cut2* (11,387 ensayos depurados) y *Cut3* (1,186 ensayos restringidos).

1. Introducción

Históricamente, la interacción humano-computadora (HCI) ha estado limitada por barreras físicas, evolucionando desde los teclados hasta las pantallas táctiles y el reconocimiento de voz. En la actualidad, las Interfaces Cerebro-Computadora (BCI, por sus siglas en inglés) proponen el siguiente salto paradigmático: traducir el pensamiento o la actividad neuronal directa en acciones computacionales [2].

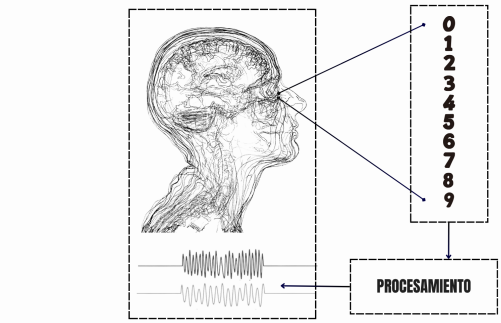


Figure 1: Flujo conceptual de una Interfaz Cerebro-Computadora (BCI).

A pesar de su inmenso potencial en áreas de salud, robótica y procesamiento de señales, el análisis de ondas cerebrales enfrenta obstáculos sustanciales. Las señales electroencefalográficas (EEG) son notoriamente ruidosas, estocásticas y susceptibles a artefactos musculares y oculares. Debido a esta complejidad, los datos cerebrales son inherentemente no separables de manera lineal, provocando que los modelos estadísticos tradicionales y algoritmos simples fracasen de manera contundente al intentar establecer fronteras de decisión precisas [3].

El presente proyecto aborda este desafío centrándose en un problema de clasificación compleja: predecir qué número (del 0 al 9) está observando un sujeto basándose únicamente en sus lecturas EEG. Para ello, se utilizará la base de datos pública *MindBigData 2022* [1], explorando tres cortes de datos (Full, Cut2 y Cut3) que varían significativamente en volumen, dimensionalidad espacial y niveles de ruido.

Dado que los modelos lineales fracasan ante la extrema no linealidad de los datos cerebrales, esta investigación plantea un **estudio comparativo de múltiples paradigmas de redes neuronales**. Se evaluará el rendimiento de arquitecturas de aproximación global (Perceptrón Multicapa - MLP) frente a modelos de aproximación local basados en vecindad topológica (Redes de Función de Base Radial - RBF). Ambas topologías serán alimentadas por características espectrales extraídas mediante la Transformada Rápida de Fourier (FFT), asegurando la viabilidad computacional. Paralelamente, se contrastarán estos resultados con enfoques avanzados de aprendizaje profundo, como las Redes Neuronales Convolucionales (CNN), capaces de extraer patrones espaciotemporales analizando los espectrogramas. Se busca determinar qué arquitectura ofrece la mayor robustez frente al ruido intrínseco del cerebro y el mejor equilibrio costo-precisión para su potencial integración en hardware de bajo costo.

2. Planteamiento del problema

El procesamiento de señales electroencefalográficas (EEG) enfrenta un problema fundamental: la altísima estocasticidad y variabilidad inter e intra-sujeto de la actividad eléctrica del cerebro. Tradicionalmente, la decodificación de estas señales ha sido una tarea extenuante que involucra un filtrado manual exhaustivo y el uso de modelos lineales estáticos que no logran generalizar las intrincadas correlaciones espaciotemporales del pensamiento. Específicamente, en la decodificación de estímulos visuales complejos, como el reconocimiento de un dígito del 0 al 9 (basado en el corpus MNIST), la señal capturada por sensores no invasivos comerciales se encuentra fuertemente contaminada por artefactos fisiológicos (musculares y oculares) y ambientales. Esto resulta en datos de naturaleza linealmente no separable [4]. En este contexto, surge la pregunta de investigación principal: ¿Cuál es la arquitectura de red neuronal (aproximación global tipo MLP, aproximación local tipo RBF, o extracción profunda tipo CNN) que ofrece el mayor rendimiento de clasificación y viabilidad computacional para decodificar estímulos visuales a partir de señales EEG ruidosas transformadas al dominio espectral?

3. Objetivos

3.1. Objetivo General

Diseñar y optimizar una arquitectura de red neuronal artificial capaz de resolver el problema de clasificación multiclase de estímulos visuales (dígitos MNIST) a partir de señales electroencefalográficas (EEG) en bruto, seleccionando el modelo más robusto frente al ruido y más eficiente computacionalmente mediante la evaluación empírica de diferentes paradigmas topológicos.

3.2. Objetivos Específicos

- **Preprocesamiento y Extracción de Características:** Procesar distintas variantes de la base de datos mediante técnicas de filtrado y transformación al dominio espectral (Transformada de Fourier) para mitigar la naturaleza estocástica del EEG y aislar las bandas cerebrales de interés.
- **Exploración de Modelos Base (MLP):** Diseñar e iterar sobre una arquitectura base tipo Perceptrón Multicapa (MLP) que sirva como punto de referencia para evaluar la capacidad de aprendizaje no lineal sobre el espacio frecuencial.
- **Evaluación de Arquitecturas Alternativas (RBF / CNN):** Explorar la factibilidad de entrenar topologías complementarias, como Redes de Función de Base Radial (RBF) orientadas a agrupación geométrica, o Redes Convolucionales (CNN), para observar cómo responden a la superposición espacial y temporal de las señales cerebrales.
- **Análisis Comparativo de Viabilidad:** Contrastar el desempeño de los algoritmos implementados analizando su convergencia, la precisión de clasificación alcanzada y su costo computacional, para determinar su idoneidad en entornos prácticos de hardware estándar.

4. Justificación

El desarrollo de Interfaces Cerebro-Computadora (BCI) tiene un impacto transformador en múltiples disciplinas, ofreciendo desde soluciones de comunicación para pacientes con síndrome de enclaustramiento (*locked-in syndrome*) hasta innovaciones en la interacción humano-máquina y entornos de realidad virtual. Sin embargo, para que las tecnologías BCI trasciendan los laboratorios clínicos y se integren a la sociedad mediante hardware comercial de bajo costo (como el casco Muse2), es imperativo optimizar los algoritmos de decodificación.

Esta investigación es justificable tecnológica y científicamente porque no se limita a construir una caja negra predictiva, sino que evalúa comparativamente distintos paradigmas neuronales (MLP, RBF, CNN). Comprender si el cerebro decodifica mejor la semántica visual a través de agrupaciones topológicas (RBF) o proyecciones globales densas (MLP) sobre los espectros de la Transformada de Fourier aportará conocimiento invaluable al estado del arte. Además, el uso de tres niveles de ruido del dataset (Full, Cut2, Cut3) permitirá dictaminar qué tanta resolución topológica (frontal vs. temporal) se necesita realmente para obtener un equilibrio óptimo entre el coste computacional y la precisión predictiva, facilitando así el desarrollo futuro de dispositivos integrados en tiempo real.

5. Estado del Arte

Históricamente, la investigación en BCI dependió de métodos de extracción manual de características y clasificadores lineales para establecer canales de comunicación directos entre el cerebro y dispositivos externos [2]. Si bien técnicas tradicionales como los Patrones Espaciales Comunes (CSP) o el Análisis de Componentes Independientes (ICA) sentaron las bases del procesamiento EEG, su aplicación exige un alto conocimiento experto y un extenso preprocesamiento [8].

La última década ha presenciado un cambio de paradigma hacia el aprendizaje profundo (*Deep Learning*). Revisiones sistemáticas recientes demostraron que las Redes Neuronales Convolucionales (CNN) se han convertido en la arquitectura dominante en la literatura de EEG (comprendiendo más del 40% de los estudios modernos) [9]. Este dominio se debe a la capacidad intrínseca de las CNN para automatizar la extracción de características (eliminando la dependencia de filtros manuales) y lidiar con la baja relación señal-ruido del cerebro [8, 9].

Investigaciones experimentales han validado empíricamente esta superioridad. Schirrmeister et al. (2017) [5] demostraron que las arquitecturas convolucionales, entrenadas de extremo a extremo sobre la señal EEG en bruto, logran igualar y superar en precisión a los algoritmos estándar de la industria (como FBCSP). Sus métodos de visualización confirmaron que la red aprende por sí sola a extraer modulaciones de potencia espectral de manera topográfica [5].

El presente proyecto se inscribe en esta frontera tecnológica. Al fusionar el problema de decodificación visual estandarizada, popularizado por LeCun et al. [6], con la base de datos *MindBigData 2022* [1], el objetivo es trasladar la potencia de las CNN y las redes de base radial (RBF) desde los costosos entornos clínicos hacia el hardware comercial de consumo.

6. Descripción del dataset



Figure 2: Dispositivo Muse2. Hardware utilizado.

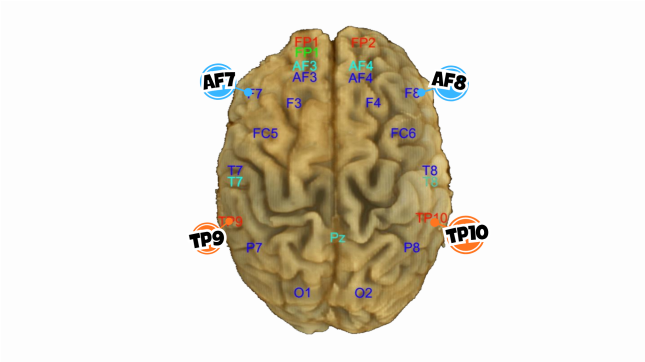


Figure 3: Disposición espacial de los sensores EEG del dispositivo comercial Muse2.

La investigación se sustenta empíricamente en la base de datos pública *MindBigData 2022* [1], un esfuerzo masivo de correlación entre estímulos visuales estandarizados y registros de EEG. El dataset fue recolectado mientras un sujeto (David Vivancos) observaba imágenes secuenciales de la base de datos MNIST (dígitos manuscritos del 0 al 9), presentadas durante 2 segundos cada una, utilizando el dispositivo comercial *Muse 2*. Para este estudio comparativo, se abordarán tres variantes (cortes) de la base de datos:

- **MindBigData Muse 2 - v0.17 (Full):** Contiene aproximadamente 72,000 instancias a nivel global. Registra la actividad de 4 canales EEG (TP9, AF7, AF8, TP10). Es la versión más dimensional y cruda, incluyendo el ruido total de los parpadeos (canales frontales AF7/AF8), ideal para evaluar la tolerancia al ruido intrínseco de los modelos.

- **Cut2:** Subconjunto depurado de 11,387 instancias. A diferencia de la versión completa, esta versión elimina los canales frontales (conservando solo TP9 y TP10), reduciendo drásticamente los artefactos de parpadeo (EOG). Posee una excelente relación señal-ruido.

- **Cut3:** Un recorte altamente restrictivo de 1,186 instancias. Conserva un canal frontal y dos temporales (TP9, AF7, TP10). Debido a su bajo volumen de datos, las señales presentan una inestabilidad estadística mayor en sus potenciales promediados (ERPs), lo cual lo hace útil para la validación rápida de prototipos o arquitecturas (pruebas de estrés *few-shot*).

Cada registro contiene series de tiempo con una frecuencia de muestreo de 256 Hz (512 muestras por cada ventana de 2 segundos). Además de los canales cerebrales, el dataset original contiene registros auxiliares periféricos (Fotopletismografía - PPG, Acelerómetro y Giroscopio). Acorde a la inspección visual previa, estos sensores somáticos serán descartados del vector de características para garantizar que los modelos aprendan exclusivamente el constructo cognitivo, previniendo correlaciones espurias de movimiento.

7. Análisis Preliminar del Dataset

El análisis exploratorio de datos reveló características fundamentales sobre la morfología de la señal y la distribución del ruido. A continuación, se presentan los hallazgos gráficos generados empíricamente utilizando las diferentes variantes del dataset, ejecutando procesamiento matricial directo en MATLAB.

7.1. Visualización en el Dominio Temporal

Las capturas en bruto demuestran una alta amplitud de ruido estocástico, tal como se ilustra en la Fig. 4, especialmente en el canal frontal (AF7), los cuales son vulnerables a los artefactos oculares y musculares (EOG/EMG)

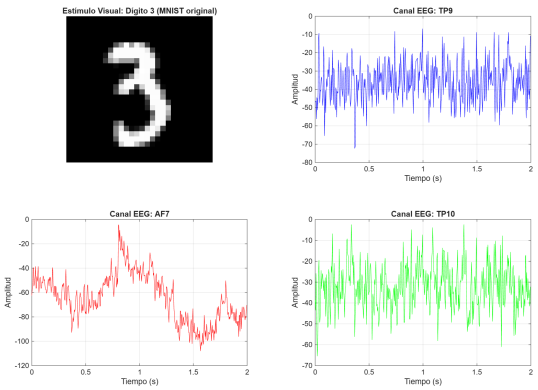


Figure 4: Serie temporal en bruto (2 segundos) para 3 canales EEG (Muse2) observando el dígito 3. Se observan picos atípicos en canal frontal, puedes ser generados por ruido o contracciones musculares.

Al promediar múltiples ensayos (generando Potenciales Relacionados con Eventos o ERP, contrastados en la Fig. 5), la estocasticidad se cancela parcialmente, revelando los picos característicos (P300/N200) de la respuesta visual semántica.

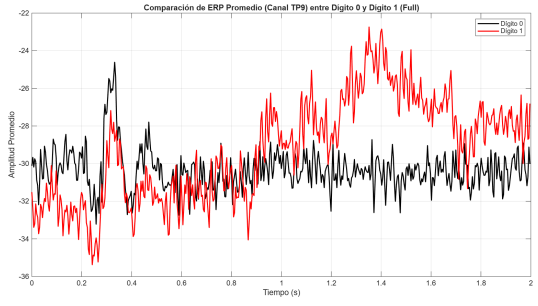


Figure 5: Comparación de ERP promedio (Canal TP9) entre la observación de los dígitos 0 y 1. Se evidencia una divergencia de voltaje que el modelo intentará clasificar.

7.2. Dispersión Tridimensional y Ruido Fisiológico Extremo:

Con el fin de inspeccionar la separabilidad espacial de los datos sin tratamiento previo, se evaluó la distribución conjunta de amplitudes para los electrodos temporales (TP9, TP10) y frontal (AF7) sobre 10,000 registros de la versión *Full* (Fig. 6). Esta visualización evidencia dos factores críticos: en primer lugar, la presencia de valores atípicos y picos de tensión severos que alcanzan hasta 1000 μV (originados por parpadeos y actividad electromiográfica en AF7, frente al rango neuronal estándar de decenas de microvoltios). En segundo lugar, se constata que las 10 clases asociadas a los dígitos visualizados se encuentran densamente entremezcladas en el espacio euclidiano, comprobando empíricamente la inseparabilidad lineal de la señal en crudo y justificando la necesidad de aplicar filtrado pasa-banda y arquitecturas neuronales con capacidad de mapeo no lineal.

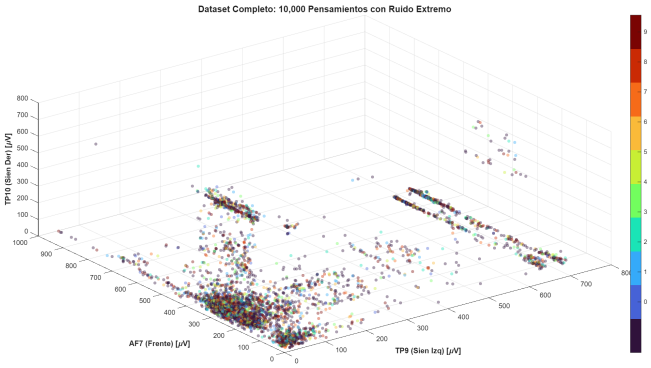


Figure 6: Dispersión tridimensional de amplitudes (μV) en los canales TP9, AF7 y TP10 para 10,000 ensayos en la variante *Full*. Se evidencia una severa superposición entre las 10 clases de dígitos y la presencia de artefactos fisiológicos de hasta 1000 μV en la señal sin filtrar.

7.3. Visualización Frecuencial: Espectrogramas y FFT

La transformación al dominio de la frecuencia mediante Transformada de Fourier confirma empíricamente que la energía electromagnética ligada al procesamiento visual y cognitivo se concentra por debajo de los 45 Hz.

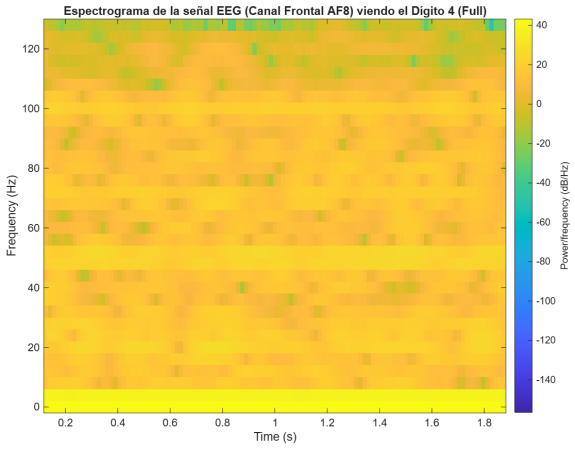


Figure 7: Espectrograma de densidad de potencia (PSD) en el tiempo para el canal frontal derecho AF8.

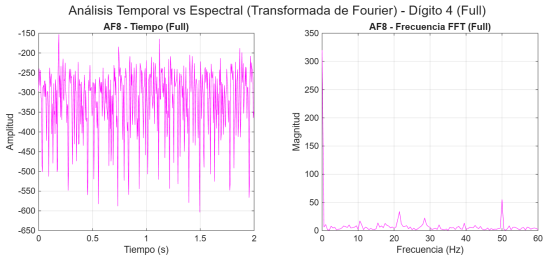


Figure 8: Distribución de magnitudes FFT separadas por bandas clásicas (Delta, Theta, Alpha, Beta, Gamma). Esta extracción será el *input* principal del MLP y RBF.

7.4. Riesgo de Fuga de Información (Data Leakage)

Dado que el dataset proviene de un único sujeto (Vivancos), el modelo resultante poseerá una especificidad inherente (modelo inter-sujeto no generalizable universalmente sin transfer learning). El riesgo de fuga de información se mitigará asegurando rigurosamente que la partición *Train/Test* se realice a nivel de ensayo aislado (*trial*), previniendo el traslape de ventanas temporales vecinas mediante una validación cruzada.

El Peligro del Data Leakage en EEG

Al provenir los datos de un solo sujeto en el mismo entorno, dos ventanas de tiempo contiguas comparten el mismo "ruido de fondo". Si una de estas ventanas queda en el set de entrenamiento y la otra en el de prueba, la red podría hacer trampa al memorizar el ruido estocástico compartido en lugar de la señal real. Por ello, la separación estricta por ensayos aislados es no negociable.

7.5. Preprocesamiento Propuesto

Con base en las gráficas temporales y espectrales obtenidas, el preprocesamiento exigirá:

1. **Descarte Sensorial:** Eliminación de variables de postura y ritmo cardíaco (Giroscopio, Acelerómetro y PPG).
2. **Filtrado:** Aplicación de un filtro pasa-banda Butterworth (0.5 - 45 Hz) para anular frecuencias de pared eléctrica y derivas térmicas (DC drift).
3. **Normalización:** Escalado Z-Score ($\mu = 0, \sigma = 1$) sobre las características finales previas a la inyección en las capas de entrada de la MLP/RBF.

8. Problema Técnico y Modelado Matemático

8.1. Naturaleza Matemática de la Señal EEG

El registro electroencefalográfico puede modelarse como un proceso estocástico multivariado continuo $x(t) \in \mathbb{R}^C$, donde C es el número de canales (electrodos). Tras el muestreo con frecuencia f_s, obtenemos una matriz discreta $\mathbf{X} \in \mathbb{R}^{C \times T}$, donde T es el número de muestras (512 puntos en ventanas de 2 segundos). El problema de decodificación BCI consiste en encontrar un mapeo no lineal $f : \mathbf{X} \rightarrow \mathbf{y}$, donde $\mathbf{y} \in \{0, 1\}^{10}$ representa el vector *one-hot* del dígito visualizado (clases del 0 al 9) [5].

8.2. Transformación al Dominio Espectral

Dado que la señal temporal $\mathbf{X}$ está severamente contaminada por ruido (fisiológico y térmico) y es altamente no estacionaria, se proyecta al dominio de la frecuencia. Para cada canal c, se calcula la Transformada Discreta de Fourier (DFT):

$$X_c[k] = \sum_{n=0}^{N-1} x_c[n] e^{-j\frac{2\pi}{N}kn} \tag{1}$$

A partir de $X_c[k]$, se calcula la Densidad Espectral de Potencia (PSD) y se extrae la energía en las 5 bandas biológicamente relevantes: Delta (δ: 0.5-4 Hz), Theta (θ: 4-8 Hz), Alpha (α: 8-12 Hz), Beta (β: 12-30 Hz) y Gamma (γ: >30 Hz) [4]. Esto reduce la matriz original $\mathbf{X}$ a un vector de características $\mathbf{v} \in \mathbb{R}^{C \times 5}$, mitigando drásticamente la maldición de la dimensionalidad.

8.3. Inseparabilidad Lineal y el Fracaso de Modelos Clásicos

La relación entre el vector espectral $\mathbf{v}$ (o la matriz temporal $\mathbf{X}$) y la intención visual $\mathbf{y}$ es inherentemente no lineal. Esto se debe a fenómenos neurofisiológicos como la conducción de volumen (mezcla espacial de las señales eléctricas antes de atravesar el cráneo), la no estacionariedad del cerebro y la altísima varianza intra-clase (observar el mismo dígito dos veces no produce exactamente la misma onda debido a pensamientos de fondo).

Bajo estas condiciones topológicas, las clases cerebrales (los dígitos del 0 al 9) forman variedades (*manifolds*) altamente retorcidas, no convexas y superpuestas en el espacio de características. Un clasificador estadístico tradicional o un modelo lineal simple (como ADALINE o Regresión Logística) intentaría separar estas clases trazando hiperplanos rígidos de la forma $\mathbf{w}^T\mathbf{v} + b = 0$. Matemáticamente, este enfoque fracasa de manera contundente porque es geométricamente imposible trazar fronteras planas que aíslen estas intrincadas agrupaciones sin incurrir en un error de clasificación prohibitivo [4].

Intuición Matemática: Manifolds

Geométricamente, un *manifold* (variedad) no lineal puede entenderse como una hoja de papel arrugada. Mientras un clasificador lineal clásico intenta separar las clases realizando un corte plano con una espada (hiperplano), las redes neuronales profundas tienen la capacidad de "desdoblar" matemáticamente el espacio topológico, logrando separar los datos que antes parecían caóticamente mezclados.

8.4. Topología de Redes para Fronteras No Lineales

Para superar la inseparabilidad lineal, este proyecto plantea evaluar y comparar tres paradigmas de aproximadores universales [3, 5], cada uno abordando la separación topológica desde una perspectiva geométrica distinta:

- **Perceptrón Multicapa (MLP) - Aproximación Global:** El MLP opera mediante proyecciones globales a lo largo de todo el espacio de características. Cada neurona oculta traza un hiperplano y aplica una función de activación no lineal (como Sigmoide): $\mathbf{h} = \sigma(\mathbf{W}\mathbf{v} + \mathbf{b})$. Al apilar múltiples capas ocultas, el MLP combina todos estos hiperplanos básicos para envolver los datos, esculpiendo fronteras de decisión globales altamente complejas y continuas a trozos que pueden adaptarse a los *manifolds* cerebrales.
- **Red de Función de Base Radial (RBF) - Aproximación Local:** A diferencia del enfoque global del MLP, la red RBF asume un enfoque topológico de vecindad local. Evalúa la similitud (basada en la distancia Euclidiana) de un nuevo vector $\mathbf{v}$ respecto a un conjunto de centroides o "prototipos" $\boldsymbol{\mu}_j$, típicamente aprendidos en una fase previa no supervisada (ej. K-Means). Utilizando una función de activación Gaussiana, $\phi_j(\mathbf{v}) = \exp\left(-\frac{||\mathbf{v}-\boldsymbol{\mu}_j||^2}{2\sigma_j^2}\right)$, la red crea "esferas de influencia" o campos receptivos. Este enfoque es excepcionalmente potente para EEG si asumimos que las respuestas cognitivas a un mismo estímulo tienden a agruparse en clústeres densos dentro del espacio frecuencial.
- **Redes Convolucionales (CNN) - Extracción Espaciotemporal:** Mientras que el MLP y la RBF requieren que aplanemos las características en un vector unidimensional $\mathbf{v}$ (destruyendo parcialmente la topología espacial de los electrodos), las CNN operan directamente sobre la estructura matricial original (ej. espectrogramas 2D o matrices de tiempo-canal 1D). Utilizan núcleos de convolución ($\mathbf{K}$) que se deslizan sobre los datos realizando el producto escalar local $\mathbf{K} * \mathbf{X}$. Esto dota a la red de un sesgo inductivo valiosísimo: aprende filtros jerárquicos invariantes a pequeñas traslaciones, extrayendo automáticamente micro-patrones (como un destello de energía repentino en la banda Gamma) que los modelos de vector aplanado podrían ignorar.

El Paradigma End-to-End

A diferencia de los métodos clásicos donde el investigador debe diseñar filtros matemáticos explícitos de forma manual, el paradigma *end-to-end* (de extremo a extremo) de la CNN permite que la red descubra por sí misma qué características espaciotemporales o frecuencias son las más relevantes para la tarea de decodificación visual.

9. Hipótesis de Trabajo

Dada la naturaleza estocástica, la alta dimensionalidad y la inseparabilidad lineal inherente a las señales electroencefalográficas (EEG) durante tareas de percepción visual, se hipotetiza que una **Red Neuronal Convolucional (CNN)** entrenada sobre representaciones espaciotemporales (espectrogramas 2D) obtendrá el mayor rendimiento de clasificación en precisión general, al ser capaz de extraer patrones invariantes a traslaciones temporales.

Sin embargo, considerando un entorno con restricciones de hardware, se hipotetiza que una topología basada en agrupaciones locales, como la **Red de Función de Base Radial (RBF)** alimentada por vectores frecuenciales compactos (bandas FFT), superará en eficiencia y precisión a un Perceptrón Multicapa (MLP) tradicional. Esto ocurriría debido a que la red RBF puede mapear la superposición de los estados cognitivos mediante campos receptivos de distancia, mientras que el modelo global MLP sufrirá un mayor grado de sobreajuste debido al ruido inter-ensayo de los canales frontales.

10. Metodología Propuesta

Para dar cumplimiento a los objetivos y someter a prueba la hipótesis, se seguirá una metodología cuantitativa, experimental e iterativa, estructurada en las siguientes fases:

10.1. Exploración y Análisis de Datos (EDA)

Se inspeccionarán estadísticamente las tres versiones de la base de datos. Utilizando herramientas de cálculo matricial, se graficarán los Potenciales Relacionados con Eventos (ERP) promediados para identificar las latencias de respuesta ante los estímulos visuales (complejos corticales visuales), y se detectarán valores atípicos (*outliers*) causados por desconexión temporal de electrodos o picos excesivos de electromiografía.

10.2. Segmentación y Preprocesamiento

Las series temporales en bruto serán sometidas a una etapa de limpieza rigurosa:

1. **Filtro Espacial:** Se descartarán explícitamente los sensores auxiliares no cerebrales (Giroscopio, Acelerómetro, PPG).
2. **Filtrado Temporal:** Se aplicará un filtro pasa-banda digital (ej. Butterworth entre 0.5 Hz y 45 Hz) para atenuar derivas térmicas de baja frecuencia y el ruido de la red eléctrica (50/60 Hz).
3. **Normalización:** Se estandarizarán los valores mediante el método *Z-Score*, garantizando que los canales con diferente impedancia contribuyan equitativamente durante la retropropagación (*backpropagation*).

10.3. Representaciones de la Señal (Feature Extraction)

La señal temporal limpia se proyectará a dos representaciones distintas para alimentar las topologías propuestas:

- **Características Espectrales (Vectores 1D):** Mediante la Transformada Discreta de Fourier (DFT), se calculará la Densidad Espectral de Potencia (PSD), extrayendo 5 magnitudes promedio por canal (bandas Delta, Theta, Alpha, Beta y Gamma). Estos vectores compactos servirán como *input* para los modelos MLP y RBF.

- **Características Espaciotemporales (Matrices 2D):** Mediante la Transformada Corta de Fourier (STFT), se construirán Espectrogramas (tiempo vs. frecuencia). Estas matrices servirán como entrada matricial directa para el aprendizaje profundo jerárquico de la CNN.

10.4. Estrategia de Partición y Entrenamiento

Para aislar completamente cualquier riesgo de fuga de información, el corpus de datos preprocesado se dividirá asegurando que ningún ensayo temporal se superponga entre los conjuntos:

- Se implementará una partición inicial estructurada (ej. 70% Entrenamiento, 15% Validación, 15% Prueba).

- Para garantizar la confiabilidad estadística y mitigar el sesgo provocado por el ruido de un solo sujeto, se empleará un esquema de **Validación Cruzada**. Tal como reportan Roy et al. [9], la omisión de técnicas de validación cruzada robustas es el principal causante de inflación de resultados y baja reproducibilidad en la literatura de DL-EEG.

- Los hiperparámetros (tasa de aprendizaje, número de centroides en RBF, tamaño de los *kernels* en CNN) se optimizarán empíricamente sobre el conjunto de validación utilizando búsqueda en cuadrícula (*Grid Search*).

11. Métricas de Evaluación

Para cuantificar y contrastar objetivamente el desempeño de las topologías neuronales (MLP, RBF, CNN) en la decodificación de los 10 dígitos visuales, se implementará un esquema de evaluación estadístico multidimensional. Dado que se aborda un problema de clasificación multiclase (dígitos del 0 al 9) sobre señales con alta varianza, basarse en una única métrica sería analíticamente engañoso. Se utilizarán las siguientes métricas:

¿Por qué no basta con la Exactitud Global?

En un problema equilibrado de 10 clases, adivinar al azar asegura ya un 10% de *Accuracy* (Exactitud). Si un modelo aprende a decodificar muy bien los números '0' y '1', pero clasifica pésimamente los demás, su Exactitud podría seguir pareciendo aceptable. Utilizar métricas adicionales como el *Macro F1-Score* previene este sesgo al promediar el rendimiento individual de cada clase equitativamente.

- **Matriz de Confusión Multiclase:** Herramienta visual y cuantitativa fundamental (matriz de 10×10). Permitirá diagnosticar si los modelos están confundiendo dígitos visual o semánticamente similares (por ejemplo, evaluar si los patrones EEG del '1' y el '7' se solapan topológicamente y causan falsos positivos cruzados).

- **Exactitud Global:** Representa el porcentaje total de predicciones correctas sobre el corpus completo de prueba. Dado que hemos estructurado un dataset balanceado, esta métrica servirá como el indicador primario de éxito superando la probabilidad del azar (la cual es estrictamente del 10% para 10 clases equiprobables).

- **Precisión por Clase:** Evalúa la proporción de verdaderos positivos sobre el total de predicciones positivas realizadas para un dígito específico. Responde a la pregunta estadística: *De todas las veces que la red predijo que el sujeto observaba un '4', ¿cuántas veces el estímulo era realmente un '4'?* Es vital para medir la robustez frente a Falsos Positivos.

- **Exhaustividad por Clase:** Evalúa la proporción de verdaderos positivos encontrados sobre el total de observaciones reales de dicha clase. Responde a la pregunta: *De todas las veces que el sujeto realmente observó un '4', ¿qué porcentaje logró capturar y decodificar la red?* Mide la resiliencia del modelo frente a Falsos Negativos (ensayos ahogados por el ruido).

- **Macro F1-Score:** Corresponde a la media armónica entre la Precisión y la Exhaustividad, calculada por clase y luego promediada de forma no ponderada (*Macro-averaging*). Se utilizará como la métrica definitiva para comparar los modelos, ya que penalizará fuertemente a cualquier red neuronal que ignore los dígitos con EEG ruidosos para concentrarse solo en los dígitos "fáciles" de decodificar.

- **Índice Kappa de Cohen (κ):** Estándar de rigor [7] en investigaciones de BCI (Interfaces Cerebro-Computadora). Cuantifica el nivel de concordancia entre las predicciones de la red y las intenciones reales del sujeto, restando la probabilidad de que los aciertos ocurran por pura casualidad estocástica, lo cual es altísimo al procesar ondas cerebrales.

12. Resultados Esperados e Hipótesis de Desempeño

En contraste con la hipótesis de trabajo (centrada en las propiedades topológicas), esta sección proyecta las métricas y los resultados cuantitativos que se esperan alcanzar durante la evaluación de los modelos. Dado que la probabilidad de adivinar un dígito por azar es estrictamente del 10% (1 entre 10 clases), se anticipan los siguientes resultados:

- **Superación del Umbral Base:** Se espera que el modelo MLP logre aislar suficientes patrones espectrales para alcanzar una exactitud global preliminar entre el 35% y 45%. Esto demostraría que la Densidad Espectral (FFT) contiene información discriminativa básica, superando en más del triple el umbral estocástico del azar.
- **Techo de Precisión por Hardware:** A diferencia del dataset MNIST de visión artificial convencional [6] (cuyos modelos rondan el 99% de precisión), se hipotetiza que el desempeño de la red óptima (CNN o RBF) enfrentará un límite asintótico en torno al $65\% - 75\%$ de Exactitud Global y Macro F1. Esta penalización es el resultado esperado debido a la pérdida de resolución espacial inherente al dispositivo comercial *Muse2* (4 electrodos vs. 64-128 de estándar clínico).
- **Impacto del Ruido en la Exhaustividad:** Se espera empíricamente que los modelos entrenados sobre la variante *Cut2* (sin canales frontales) arrojen métricas de precisión superiores frente a la versión *Full*. No obstante, se hipotetiza que la topología CNN será la única capaz de mantener una alta Exhaustividad en la base *Full*, filtrando jerárquicamente el severo ruido ocular de los electrodos AF7/AF8.
- **Métricas de Costo Computacional:** En términos de rendimiento algorítmico, se hipotetiza que la CNN registrará el mayor tiempo de convergencia. Inversamente, la red RBF registrará el mayor costo de propagación hacia adelante al calcular distancias Euclidianas contra múltiples centroides. El MLP se perfilará como la topología más ligera para un eventual despliegue en tiempo real.

13. Limitaciones y Riesgos

El desarrollo de este proyecto se encuentra sujeto a limitaciones inherentes tanto a la biofísica de la señal cerebral como a la arquitectura matemática de los modelos. Identificar estos riesgos empíricamente es crucial para acotar de forma realista el alcance de la investigación:

13.1. Riesgos Inherentes a los Datos (Señal EEG)

- **Resolución Espacial del Hardware:** El dispositivo comercial *Muse2* cuenta únicamente con 4 electrodos activos (TP9, AF7, AF8, TP10). Esto representa una severa limitación espacial frente a los estándares de grado médico (64 a 128 canales), restringiendo drásticamente la topología cerebral que los modelos pueden explorar e interconectar.
- **Susceptibilidad a Artefactos Fisiológicos:** La señal cognitiva opera en el rango de los microvoltios (μV), mientras que el ruido generado por parpadeos (EOG) o tensión de la mandíbula (EMG) puede ser órdenes de magnitud mayor. Especialmente en la variante *Full*, existe el riesgo crítico de que la red aprenda a clasificar "patrones sutiles de parpadeo" subconscientes al ver un dígito, en lugar del constructo semántico del cerebro puro.
- **Falta de Generalización Inter-Sujeto:** Debido a que la totalidad de los datos extraídos provienen de un único individuo (Vivancos) [1], las fronteras de decisión estarán íntimamente adaptadas a la topografía craneal y firma electrofísica de dicha persona. El despliegue de estos modelos en usuarios distintos sufrirá caídas de rendimiento masivas a menos que se implemente una etapa de *Transfer Learning*, un desafío que sigue siendo catalogado como una de las mayores barreras actuales en la neuroingeniería [8, 9].

13.2. Riesgos Arquitectónicos de los Modelos

- **Perceptrón Multicapa (MLP) - Pérdida Topológica:** El riesgo principal del MLP radica en su diseño global denso. Al requerir el aplanamiento (*flatten*) de los espectros de entrada, se destruyen las relaciones jerárquicas entre los electrodos frontales y temporales. Esto incrementa el riesgo de *Overfitting* (sobreajuste), ya que la red podría empezar a memorizar variaciones estocásticas en lugar de generalizar.
- **Redes de Base Radial (RBF) - Maldición de la Dimensionalidad:** Las RBF dependen de la distancia Euclidiana en el espacio de características. Si el ruido biológico inyecta una varianza extrema a las bandas de Fourier extraídas, los clústeres matemáticos colapsarán. Esto causaría que los centroides aprendidos en la fase de agrupamiento terminen posicionados en "zonas muertas" del espacio, imposibilitando la activación correcta de la función Gaussiana.
- **Redes Convolucionales (CNN) - Riesgo por Déficit de Instancias:** Las CNN son arquitecturas que requieren volúmenes masivos de información. Particularmente en cortes del dataset como el *Cut3* (con solo 1,186 muestras), la CNN corre el riesgo inminente de sobreajustarse memorizando los espectrogramas en muy pocas iteraciones. Será estrictamente necesario blindar la red aplicando alta regularización (*Dropout*, *Weight Decay*) y esquemas de *Early Stopping*.

14. Entregables

Para garantizar la viabilidad técnica del proyecto y un desarrollo estructurado, la investigación empírica y el desarrollo del software se dividirán en dos entregas formales. Esto asegura un avance sustancial intermedio y un cumplimiento escalonado de los objetivos propuestos:

14.1. Entrega 1: Fundamentación de Datos y Modelo Base

Esta entrega inicial resolverá la etapa crítica de tratamiento de la señal EEG y establecerá el punto de referencia de aprendizaje automático, dando cumplimiento a los dos primeros objetivos específicos. Estará conformada por:

- **Pipeline de Preprocesamiento:** Algoritmos y *scripts* que ejecutan la limpieza de la señal bruta, la aplicación del filtrado pasa-banda, la segmentación y el escalado *Z-Score*.
- **Módulo de Extracción Espectral:** Códigos implementados para la extracción de características mediante la Transformada Discreta de Fourier (FFT), generando los tensores frecuenciales para las cinco bandas cerebrales.
- **Despliegue del Modelo MLP:** Diseño, entrenamiento y validación de la topología densa de referencia (Perceptrón Multicapa).
- **Informe de Avance Parcial:** Documento técnico que contenga el Análisis Exploratorio de Datos (EDA) y reporte las métricas preliminares del MLP, demostrando empíricamente que la red logra aprender y superar el umbral estocástico del azar (10%).

14.2. Entrega 2: Arquitecturas Avanzadas y Conclusión del Problema

La entrega final integrará el entrenamiento de las redes topológicas complejas, consolidando el análisis comparativo para dar cumplimiento al objetivo general y respuesta definitiva al problema técnico. Estará compuesta por:

- **Implementación de Modelos RBF y CNN:** Código fuente funcional, entrenado y optimizado de la Red de Función de Base Radial y de la Red Neuronal Convolucional (esta última alimentada mediante espectrogramas 2D).
- **Evaluación Comparativa de Desempeño:** Tablas de métricas definitivas (Exactitud Global, Macro F1, Kappa de Cohen, Tiempos de Inferencia) y Matrices de Confusión que contrasten a las tres redes (MLP, RBF, CNN) frente a los diferentes escenarios de ruido del dataset (*Full* vs *Cut2*).
- **Documento de Artículo Final:** Entrega definitiva de esta propuesta transformada en informe final. Contendrá el reporte riguroso de los hallazgos, la validación o refutación matemática de la hipótesis de trabajo, y la conclusión técnica indicando qué paradigma topológico resultó superior para la decodificación BCI.

15. Conclusiones Preliminares

A partir del Análisis Exploratorio de Datos (EDA) ejecutado de forma empírica sobre las diversas variantes de la base de datos *MindBigData 2022*, se derivan las siguientes conclusiones preliminares que ratifican la dirección técnica del proyecto:

- **Presencia de Patrones Latentes:** A pesar de la severa estocasticidad macroscópica de la señal cruda, la generación de Potenciales Relacionados con Eventos (ERP) reveló divergencias de voltaje significativas ante estímulos visuales distintos (ej. contraste entre la visualización del dígito 0 y el dígito 1). Esto confirma la viabilidad fundamental de la propuesta: la señal EEG del hardware comercial *Muse2* efectivamente codifica la intención semántica visual.
- **Necesidad Crítica de Extracción Espectral:** La abrumadora varianza en el dominio del tiempo comprobó empíricamente que inyectar la señal bruta directamente a un modelo plano (MLP) sería fútil y propenso al colapso por *Overfitting*. La transformación al dominio de la frecuencia mediante Transformada de Fourier demostró ser el paso de preprocesamiento óptimo, compactando exitosamente la información estocástica en bandas de energía estables por debajo de los 45 Hz.
- **Vulnerabilidad ante Artefactos Fisiológicos:** La inspección de la base de datos completa (*Full*) evidenció que los canales frontales (AF7, AF8) inyectan picos de amplitud masivos (artefactos EOG por parpadeo). Esto valida la decisión metodológica de entrenar los modelos también sobre variantes depuradas (como *Cut2*) para garantizar que la red neuronal aprenda el constructo cognitivo occipital/temporal, y no simplemente el patrón de parpadeo subconsciente del usuario.
- **Inadecuación de Fronteras Lineales:** La altísima superposición cruzada observada en los mapas de calor y espectrogramas justifica teóricamente el rechazo a clasificadores estadísticos simples (regresiones lineales, perceptrón simple). El problema exige de forma perentoria la capacidad de trazar fronteras de decisión no lineales complejas, respaldando plenamente el estudio comparativo planteado entre la proyección global (MLP), la agrupación topológica local (RBF) y la extracción jerárquica profunda (CNN).

References

[1] Vivancos, D. (2022). *MindBigData 2022: The "Visual MNIST" Brain Dataset*. Recuperado de la plataforma MindBigData.

[2] Wolpaw, J. R., Birbaumer, N., McFarland, D. J., Pfurtscheller, G., & Vaughan, T. M. (2002). *Brain-computer interfaces for communication and control*. Clinical neurophysiology, 113(6), 767-791.

[3] Haykin, S. (2009). *Neural networks and learning machines* (3rd ed.). Pearson Education.

[4] Sanei, S., & Chambers, J. A. (2013). *EEG signal processing*. John Wiley & Sons.

[5] Schirrmeister, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggensperger, K., Tangermann, M., ... & Ball, T. (2017). *Deep learning with convolutional neural networks for EEG decoding and visualization*. Human brain mapping, 38(11), 5391-5420.

[6] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). *Gradient-based learning applied to document recognition*. Proceedings of the IEEE, 86(11), 2278-2324.

[7] Cohen, J. (1960). *A coefficient of agreement for nominal scales*. Educational and psychological measurement, 20(1), 37-46.

[8] Craik, A., He, Y., & Contreras-Vidal, J. L. (2019). *Deep learning for electroencephalogram (EEG) classification tasks: a review*. Journal of Neural Engineering, 16(3), 031001.

[9] Roy, Y., Banville, H., Albuquerque, I., Gramfort, A., Falk, T. H., & Faubert, J. (2019). *Deep learning-based electroencephalography analysis: a systematic review*. Journal of Neural Engineering, 16(5), 051001.